

UNIVERSIDADE DE DRACENA
CURSO DE TECNOLOGIA EM ANÁLISE E DESENVOLVIMENTO DE SISTEMAS

Heitor Reyes Sanches

**Projeto e Desenvolvimento de um Sistema para
Diarização de locutores**

Dracena

2025

Heitor Reyes Sanches

Projeto e Desenvolvimento de um Sistema para Diarização de locutores com foco na língua portuguesa

Trabalho de conclusão de curso de graduação
apresentado à Universidade de Dracena como
requisito parcial para a obtenção do título de
Tecnólogo.

Orientador: Prof. Me. Bruno Conti Marini

Heitor Reyes Sanches

**Projeto e Desenvolvimento de um Sistema para
Diarização de locutores com foco na língua portuguesa**

Trabalho de conclusão de curso de graduação apresentado à Universidade de Dracena como
requisito parcial para a obtenção do título de Licenciado.

Aprovado em: ____ de _____ de ____.

BANCA EXAMINADORA

Nome do professor - instituição

Nome do professor - instituição

Nome do professor - instituição (orientador)

RESUMO

A Inteligência Artificial surge como uma força transformadora no século XXI, redefinindo paradigmas em diversos setores e impulsionando inovações tecnológicas. No Brasil, o interesse pela inteligência artificial cresce, reconhecida como ferramenta estratégica para superar desafios e acelerar o desenvolvimento econômico. Sua integração no cotidiano e nas empresas promove automação, análise de dados e inovação, mas enfrenta barreiras como custos elevados, escassez de profissionais qualificados e limitações de infraestrutura. Essa dualidade destaca a necessidade de soluções acessíveis, como ferramentas de código aberto para transcrição e diarização de áudio, garantindo privacidade e soberania de dados em execução local. Portanto, o presente trabalho dispõe-se a criar uma ferramenta open source que facilite a utilização de tais ferramentas.

ABSTRACT

Artificial Intelligence emerges as a transformative force in the 21st century, redefining paradigms across sectors and driving technological innovations. In Brazil, interest in artificial intelligence grows, recognized as a strategic tool to overcome challenges and accelerate economic development. Its integration into daily life and businesses promotes automation, data analysis, and innovation, but faces barriers such as high costs, shortage of skilled professionals, and infrastructure limitations. This duality underscores the need for accessible solutions, like open-source tools for audio transcription and speaker diarization, ensuring privacy and data sovereignty in local execution. Therefore, this work aims to create an open source tool that facilitates the use of such tools.

LISTA DE ABREVIATURAS E SIGLAS

IA	Inteligência Artificial
LLMs	Large Language Models
MFCC	Mel-Frequency Cepstrum Coefficients
FFT	Fast Fourier transform
DCT	Discrete cosine transform
VAD	Voice activity detection
ASR	Automatic Speech Recognition
HMM	Hidden Markov Model
GMM	Gaussian Mixture Model
DNN	Deep Neural Network
CNN	Convolutional Neural network
RNN	Recurrent Neural Networks

SUMÁRIO

SUMÁRIO

1 INTRODUÇÃO	7
2 Desenvolvimento	10
3 Conclusões	18
REFERÊNCIAS	20

1 INTRODUÇÃO

A IA emergiu como uma das forças mais transformadoras do século XXI, redefinindo paradigmas em diversos setores e impulsionando uma nova era de inovação tecnológica [1]. No Brasil, o interesse e o investimento em IA têm crescido exponencialmente nos últimos anos [2], com a tecnologia sendo reconhecida como um ativo estratégico para o enfrentamento de desafios domésticos e a aceleração do crescimento econômico [3]. A inserção da IA no cotidiano das pessoas e no ambiente corporativo tem registrado um crescimento exponencial. Pesquisas indicam que, em junho de 2024, 72% das empresas em todo o mundo já haviam adotado tecnologias que fazem uso de IA de alguma maneira, um avanço significativo em comparação com os 55% registrados em 2023. Este cenário de expansão tecnológica convoca profissionais e organizações a uma transformação digital profunda, com a IA liderando o ranking das tecnologias mais utilizadas nesse processo, atingindo 69% de adoção e um crescimento de 28 pontos percentuais [4].

No contexto brasileiro, a adoção da IA é igualmente expressiva. Dados recentes revelam que 74% das empresas brasileiras já utilizam IA em algum nível, seja para automação de processos, análise de dados ou inovação em produtos e serviços [5]. Um quarto dessas empresas já implementou pelo menos um caso de uso baseado em IA generativa. A IA generativa, em particular, é vista como uma das cinco prioridades estratégicas para 67% das organizações no país, e para 17% delas, já constitui o foco principal de investimentos. Empresas que implementam a IA generativa têm observado um aumento médio de 14% na produtividade e um crescimento de 9% nos resultados financeiros [6].

Apesar dos benefícios evidentes, a expansão da IA no Brasil não está isenta de desafios e preocupações [7]. Existe uma dualidade inerente à IA: ao mesmo tempo em que é um catalisador de desenvolvimento, também é uma fonte de novas preocupações [8]. Um dos obstáculos mais críticos é o custo elevado, apontado como a principal barreira para a adoção da Inteligência Artificial entre empresas no Brasil, superando até mesmo as dificuldades de integração e a escassez de talentos. Embora o governo brasileiro tenha planos de investir bilhões em IA, incluindo R\$ 1,76 bilhão para aprimoramento dos serviços públicos [9], o alto custo inicial de implementação permanece um desafio generalizado, afetando tanto o setor privado quanto o público.

Além do custo direto de aquisição de software, a implementação de soluções de IA exige a disponibilidade de profissionais qualificados para integrar e alimentar os sistemas. No entanto, o Brasil enfrenta uma notável escassez de talentos: 73% das empresas que utilizam IA não possuem equipes dedicadas, e projeta-se um déficit de 530 mil profissionais na área de tecnologia até 2025. Essa carência de mão de obra especializada eleva os custos indiretos e dificulta a plena exploração do potencial da IA [5].

Outro fator de custo significativo reside na infraestrutura de hardware, especialmente a computação em nuvem, essencial para o aprendizado de máquina. Vale notar que a contratação de serviços de LLMs como Gemini [10], Chatgpt [11] ou Grok [12] não seria viável pois eles executam seu próprio código e, neste caso, seria necessária a execução de código próprio. A escassez de data centers com capacidade para processamento de grandes volumes de informações e a falta de acesso à internet de alta qualidade em muitas regiões limitam a implementação de soluções robustas de IA. Embora existam ofertas de créditos para novos clientes em plataformas de nuvem, o custo de hospedagem e processamento para cargas de trabalho de machine learning pode ser substancialmente alto.

Relatórios recentes projetam um déficit alarmante de 530 mil profissionais na área de tecnologia até 2025, conforme estimativas do Google for Startups[13]. A Associação Brasileira das Empresas de Tecnologia da Informação e Comunicação (Brasscom) corrobora essa projeção, estimando um déficit de 532 mil profissionais em áreas tecnológicas até o final de 2025[14].

O desequilíbrio entre a oferta e a demanda é gritante: entre 2021 e 2025, anualmente, apenas 53 mil profissionais devem se formar, um número claramente insuficiente para preencher as

quase 800 mil novas vagas que teriam sido criadas no período[13]. A demanda por profissionais com habilidades em IA cresceu em média 21% ao ano desde 2019, superando significativamente a oferta de talentos no mercado[15]. O número de vagas de emprego que exigem conhecimentos em IA quase quadruplicou entre 2021 e 2024, saltando de 19 mil para 73 mil [16]. A principal causa dessa escassez reside no desequilíbrio entre a oferta de trabalho e a disponibilidade de talentos, impulsionado pela progressiva digitalização das empresas em diversos segmentos, que aumenta exponencialmente a necessidade por profissionais capacitados [17].

Diante do exposto, o presente trabalho se justifica por sua relevância no contexto de um mercado de tecnologia em franca expansão no Brasil, contudo essa expansão enfrenta barreiras significativas, como os custos elevados de soluções comerciais de IA, que operam em modelos de pagamento por uso, e a dependência de infraestrutura de nuvem, que podem ser proibitivos para pequenos negócios, profissionais liberais e estudantes. A proposta de utilizar ferramentas de código aberto como pyannote [18][19] e Whisper [20] em um ambiente de execução local oferece uma alternativa de baixo custo, que garante privacidade e soberania dos dados. O principal diferencial e a inovação em usabilidade deste TCC residem na funcionalidade de permitir que o usuário renomeie os rótulos genéricos dos locutores para nomes reais, tornando a transcrição imediatamente acionável e relevante para o contexto, uma característica valorizada em soluções de mercado.

Diante disso, o objetivo geral do TCC é desenvolver e validar uma aplicação de software que integre de forma sinérgica o pyannote e o Whisper para realizar a transcrição e a diarização de locutores. Os objetivos específicos são: implementar um algoritmo para alinhar os resultados de tempo de cada ferramenta, superando o desafio técnico da sobreposição temporal ; criar uma interface gráfica intuitiva que permita o carregamento de arquivos de áudio, a visualização estruturada da transcrição e a personalização dos nomes dos locutores; e, finalmente, avaliar a eficácia e usabilidade da aplicação para demonstrar a viabilidade e o valor da abordagem de código aberto como uma solução robusta e acessível no mercado brasileiro. O projeto não é apenas um exercício técnico, mas uma prova de conceito que demonstra como a inovação em IA pode ser democratizada, gerando valor real para uma base de usuários mais ampla e superando as barreiras de custo e acesso a tecnologias proprietárias.

2 DESENVOLVIMENTO

Claro que o processo mencionado no parágrafo anterior não é simples. Para tornar nosso objetivo uma realidade, precisamos primeiro entender melhor o problema que será tratado e como podemos solucioná-lo. Em um primeiro momento, o problema maior é conseguir segmentar o arquivo de áudio, identificar quem é o locutor de cada segmento e, finalmente, transcrever o segmento para texto.

Para isso, são necessárias duas redes neurais distintas: uma para diarização de locutores, identificando falantes em áudios multimídia, e outra para transcrição automática do conteúdo falado.

A diarização de locutor, que consiste na identificação de diferentes vozes em um conteúdo multimídia, permitindo a separação temporal dos falantes e respondendo à pergunta fundamental: “Quem falou quando?” [21]. O avanço do aprendizado de máquina, especialmente com técnicas baseadas em redes neurais, tem aprimorado a capacidade de generalização e robustez dos sistemas de diarização, como exemplificado em [22]. Essa evolução, combinada com métodos tradicionais como o “Segregation of Speakers” [23] e o “Bayesian Information Criterion” [24] e abordagens modernas como “Attention-based Encoder–Decoder End-to-End Neural Diarization” [25] tem permitido avanços significativos, embora desafios como a variabilidade da qualidade de áudio e a complexidade dos ambientes de gravação continuem a demandar esforços e pesquisas.

A complexidade da diarização de locutor reside, em grande parte, na variabilidade e nas nuances do som humano. Cada falante apresenta características únicas, como timbre, sotaque, entonação e ritmo, que podem variar significativamente mesmo em contextos semelhantes. Além disso, a presença de ruídos de fundo, sobreposição de vozes e variações de volume exigem que os sistemas de diarização sejam robustos e capazes de operar em condições adversas [26].

Para conseguir identificar diferentes falantes em um arquivo de áudio, precisamos primeiro extrair as características da voz do locutor, isso é possível fazer usando MFCC [27]. O MFCC é uma representação compacta do espectro de áudio, e o seu cálculo é um processo de múltiplos passos que já inclui a FFT [28].

O fluxo de trabalho para o cálculo do MFCC é primeiramente dividir o sinal de áudio em pequenos segmentos curtos (enquadramento e janelamento). Após é aplicada a FFT para cada segmento para converter o sinal do domínio do tempo para o domínio da frequência. Em seguida o espectro de frequência é então filtrado por um banco de filtros de Mel, que imita a audição humana. Após o logaritmo é aplicado à energia, quantidade de potência do sinal presente naquela faixa de frequência, de cada filtro para simular a percepção logarítmica de volume do ouvido humano. Finalmente, a DCT é aplicada para descorrrelacionar os coeficientes, resultando nos MFCCs finais, [28] como podemos ver na figura 1.




Figura 1: Processo do cálculo do MFCC [29].

A complexidade de desenvolver um sistema de diarização de locutores do zero, no entanto, vai muito além do processamento de sinais. Construir um sistema completo e robusto é um desafio técnico e de pesquisa, exigindo conhecimentos profundos em processamento de fala e aprendizado de máquina. Um estudo que implementou redes neurais recorrentes em 2021, por exemplo, obteve resultados "pouco competitivos" em um desafio com áudios complexos, com uma taxa de erro de diarização (DER) de mais de 60%, demonstrando o quão difícil é a tarefa [30].

Por isso, em vez de desenvolver tudo do zero, o uso de bibliotecas de diarização de locutor prontas, como a pyannote, é uma escolha estratégica e eficiente. A pyannote é um kit de ferramentas de código aberto escrito em Python que oferece blocos de construção neurais e modelos pré-treinados para a diarização de locutores.

A pyannote já vem com modelos pré-treinados que atingem desempenho de ponta. A pyannote.audio já alcançou o primeiro lugar em desafios como o Ego4D 2022 [31], superando

outras soluções. Além da diarização principal, a biblioteca oferece componentes separados para tarefas cruciais, VAD para identificar quando há fala em um áudio, detecção de fala sobreposta (quando múltiplos locutores falam ao mesmo tempo), e extração de embeddings de locutor. A arquitetura é baseada em uma pipeline modular, que combina a detecção de fala, a extração de embeddings e o agrupamento (clustering) para identificar locutores únicos. Isso permite que cada componente seja otimizado, e que a ferramenta seja flexível para diferentes cenários [32]. Além de ser uma biblioteca extremamente avançada, ela tem uma API que é fácil de usar e permite implementar um sistema de diarização com apenas algumas linhas de código. Ela pode ser usada para extrair uma "impressão digital" única de uma voz e é capaz de rastrear locutores específicos em diversas conversas. Toda a estrutura da diarização pode ser vista a seguir na figura 2.




Figura 2: Estrutura da pipeline de diarização do pyannote [33].

Com a diarização definida, precisamos falar da transcrição de áudio, também conhecida como gravação, é um processo que consiste na conversão de um arquivo de áudio ou vídeo em um texto escrito [34]. Essa prática é fundamental para tornar o conteúdo de materiais gravados acessível, pesquisável e analisável de forma mais eficiente. A necessidade de converter a fala em texto surge em uma ampla variedade de contextos, desde o ambiente acadêmico, onde estudantes buscam transcrever palestras para facilitar o estudo posterior, até a pesquisa, onde entrevistas precisam ser transcritas para uma análise detalhada do material coletado [35].

Além disso, a transcrição profissional se aplica a audiências, videoconferências e cursos, onde a precisão e a confiabilidade são essenciais para o propósito do documento. Uma transcrição de alta qualidade deve ser auto suficiente, permitindo a compreensão completa do conteúdo sem a necessidade de consulta ao arquivo original de áudio. Para alcançar esse nível de excelência, são aplicadas textualizações e pontuações adequadas, o que diferencia significativamente um trabalho profissional de um amador [36].

Antes da ascensão do deep learning, a arquitetura dominante para ASR era baseada em HMM e GMM [37]. Os HMMs foram fundamentais para lidar com a variabilidade temporal da fala. Nesses modelos, a fala é vista como uma sequência de estados ocultos, que correspondem aos fonemas, as unidades básicas de som de uma língua. Cada estado oculto tem uma probabilidade de transição para o próximo estado e uma probabilidade de "emitir" uma determinada observação [38].

O objetivo do sistema era encontrar a sequência de fonemas mais provável que correspondesse à sequência de observações acústicas. Para resolver esse problema de forma eficiente, era utilizado o algoritmo de Viterbi [39], que, por meio de programação dinâmica, encontrava o caminho mais provável através da rede de estados de HMM em tempo polinomial, evitando a complexidade exponencial de uma busca exaustiva [38]. Embora os HMMs fossem considerados de ponta por um tempo, a sua complexidade e a dificuldade de modelar as nuances da fala levaram à busca por abordagens mais poderosas.

A partir dos anos 2000, e com o avanço da computação e de novos algoritmos de aprendizado de máquina, as DNNs começaram a superar os modelos GMM-HMM. As DNNs se mostraram capazes de extrair características mais complexas e de baixa dimensão da forma de onda da fala, superando a necessidade de pré-processamento altamente projetado dos modelos anteriores. Um artigo de revisão de 2012 destacou que as redes neurais profundas superaram

os GMMs em diversas tarefas de reconhecimento de fala, às vezes por uma margem considerável, o que marcou uma mudança de paradigma no campo. A capacidade das DNNs de modelar a estrutura subjacente da fala de forma mais eficiente e sua flexibilidade para generalizar a novos dados as tornaram a base das arquiteturas ASR modernas [37].

A transição para o deep learning levou a uma variedade de arquiteturas de ponta, incluindo CNNs, RNNs e Transformers. Esses modelos não apenas melhoraram a precisão do reconhecimento de fala, mas também abriram caminho para sistemas mais robustos e adaptáveis [37].

Por conta da complexidade e falta de tempo para se criar uma rede neural capaz de fazer a transcrição, foi escolhido usar uma biblioteca de código aberto Whisper com mais de 8000 horas de treino na língua portuguesa para fazer o reconhecimento da fala [20].

O treinamento da rede neural Whisper foi utilizada a arquitetura ASR, os dados da rede neural foram retirados pela internet, afastando-se dos tradicionais conjuntos de dados de alta qualidade, porém limitados, em favor de uma abordagem de “supervisão fraca em larga escala” [20]. base do seu sucesso reside num monumental conjunto de dados de 680.000 horas de áudio, coletado da internet, que é inerentemente diverso em sotaques, ruído de fundo, idiomas e jargões técnicos [20]. Cerca de um terço desses dados é não-inglês, e 125.000 horas são dedicadas especificamente ao treinamento da tarefa de tradução de fala para o inglês, o que confere ao modelo sua robustez e capacidade de generalização zero-shot, [20] onde o zero-shot é um cenário de aprendizado de máquina no qual um modelo de IA é treinado para reconhecer e categorizar objetos ou conceitos sem ter visto nenhum exemplo dessas categorias ou conceitos com antecedência [40].




Figura 3: Estatísticas do conjunto de dados de treinamento do pyannote [20].

Contudo, temos um problema com o Whisper, o problema reside na precisão temporal das marcações de tempo (timestamps). O modelo Whisper, por padrão, embora gere transcrições textuais altamente precisas, fornece timestamps em nível de sentença ou segmento (utterance-level). Pesquisas e testes práticos demonstram que essas marcações podem ser imprecisas, com desvios de vários segundos em relação ao início e fim reais da fala [41].

Para superar as limitações expostas, será utilizado a biblioteca WhisperX [41]. O WhisperX não é um novo modelo de ASR, mas sim um sistema de código aberto que aprimora o Whisper da OpenAI. Ele foi projetado especificamente para gerar transcrições com marcações de tempo em nível de palavra (word-level timestamps) de alta precisão e integrar a diarização de locutores de forma robusta [42].

O WhisperX, alcança alta precisão na transcrição e sincronização de fala por meio de um pipeline composto por quatro etapas sequenciais [41]. Primeiro, na segmentação por Detecção de Atividade de Voz (VAD), o áudio é analisado para identificar trechos de fala e silêncio, agrupando as partes faladas em segmentos de cerca de 30 segundos, delimitados por pausas naturais. Em seguida, ocorre a transcrição em lote, em que esses segmentos são processados paralelamente pelo modelo Whisper, gerando transcrições textuais precisas, embora com timestamps temporais imprecisos. A terceira etapa, o alinhamento forçado com um modelo treinado de máquina wav2vec2 [43], é o diferencial técnico do WhisperX: aqui, o texto transcrito é alinhado ao áudio com precisão de milissegundos, aproveitando a força do wav2vec2 em gerar alinhamentos temporais exatos em nível de palavra, combinando assim a alta acurácia textual do Whisper com a precisão temporal do wav2vec2. Por fim, na etapa de diarização e fusão dos resultados, o sistema utiliza o pyannote.audio para identificar os diferentes locutores e seus intervalos de fala. Esses dados são então integrados aos timestamps das palavras, atribuindo a cada uma delas um rótulo de locutor correspondente. O resultado final é uma transcrição completa, precisa tanto no conteúdo quanto no tempo e na identificação dos falantes [41].

Finalmente, o WhisperX, assim como o Whisper e o pyannote, é uma ferramenta de código aberto que pode ser executada localmente. Isso cumpre os requisitos de privacidade, soberania de dados e baixo custo. A eficiência do WhisperX (velocidade e processamento em lote) o torna ainda mais viável para execução em hardware de consumo, democratizando o acesso à tecnologia.




Figura 4: O sistema do WhisperX para transcrição eficiente de áudio longo com alinhamento temporal em nível de palavra [41].

Continuando o desenvolvimento do projeto, a escolha da arquitetura do frontend foi guiada pelos desafios e objetivos delineados na Introdução, nomeadamente a necessidade de uma solução de baixo custo, alta performance e que garantisse a privacidade e soberania dos dados através da execução local. A seleção do framework Tauri [44] representa uma decisão arquitetônica fundamental, respondendo diretamente aos problemas de custo e dependência de infraestrutura de nuvem identificados na análise de requisitos.

Diferente de frameworks alternativos como o Electron [45], o Tauri não embute um motor de navegador completo (como o Chromium) em cada aplicação. Em vez disso, ele utiliza a webview nativa do sistema operacional.

As aplicações desenvolvidas com Tauri apresentam um tamanho de bundle mínimo de aproximadamente 600 KB [44], o que representa uma diferença significativa em relação aos mais de 85 MB dos instaladores base do Electron [46], tornando a distribuição da aplicação muito mais leve e acessível. O Electron gera aplicativos grandes e pesados, com binários de até 120 MB e alto consumo de memória, apesar da boa compatibilidade entre plataformas. Já o Tauri é muito mais leve e rápido, com arquivos de cerca de 3 MB, menor uso de RAM e inicialização quase instantânea. Além disso, o backend em Rust torna o Tauri mais seguro, limitando o acesso ao sistema, enquanto o Electron exige mais cuidado com segurança. Assim, o Tauri se destaca por eficiência e proteção, embora sua adoção dependa do caso de uso [47]. Esse baixo consumo de recursos é essencial para garantir um bom desempenho em dispositivos com hardware mais modesto, que constituem um dos principais públicos-alvo do projeto. Por fim, o tempo de inicialização também é notavelmente menor, a aplicação pode ser aberta em menos de meio segundo, proporcionando uma experiência de utilização mais fluida e semelhante à de aplicações nativas.

3 CONCLUSÕES

O presente trabalho atingiu com êxito seu objetivo principal de desenvolver e validar uma aplicação de software local para transcrição e diarização de locutores, integrando ferramentas de código aberto de alto desempenho. A solução final demonstra que é possível superar as barreiras de custo elevado e dependência de infraestrutura em nuvem, oferecendo uma alternativa robusta que preserva a privacidade e a soberania dos dados do usuário.

A aplicação desenvolvida revelou-se eficaz na integração sinérgica dos modelos, aproveitando a capacidade multilíngue do Whisper e a precisão de diarização do pyannote, refinados pelo alinhamento temporal do WhisperX. O resultado é um programa capaz de diarizar e transcrever áudios em diversas línguas com alta acurácia, operando inteiramente em ambiente local.

Para validar a viabilidade técnica da solução proposta em diferentes cenários de hardware, foi realizada uma análise comparativa de desempenho. Os testes confrontaram os modelos Whisper Turbo e WhisperX Large-v2 em duas configurações de processamento distintas: uma CPU 1 (Intel Core i3-10100F @ 3.60GHz, 8 CPUs) e uma CPU 2 (Intel Core i7-11700F @ 2.50GHz, 16 CPUs). Foram processados dois arquivos de áudio: Áudio 1 (4:58 minutos, 516 palavras) e Áudio 2 (10:27 minutos, 1013 palavras).

Os resultados obtidos, detalhados nas Tabelas 1 e 2, revelam dinâmicas de desempenho complexas, que dependem diretamente da arquitetura do processador.

Tabela 1: Desempenho do Modelo Whisper Turbo (Modelo Base)

CPU	Transcrição ÁUDIO 1	Diarização ÁUDIO 1	Transcrição ÁUDIO 2	Diarização ÁUDIO 2
CPU 1	4 min 17 seg	6 min 8 seg	10 min 40 seg	7 min 22 seg
CPU 2	6 min 8 seg	4 min 19 seg	13 min 54 seg	9 min 28 seg

Tabela 2: Desempenho do Modelo WhisperX (Large-v2)

CPU	Transcrição ÁUDIO 1	Alinhamento ÁUDIO 1	Diarização ÁUDIO 1	Transcrição ÁUDIO 2	Alinhamento ÁUDIO 2	Diarização ÁUDIO 2
CPU 1	4 min 02 seg	1 min 18 seg	3 min 29 seg	8 min 32 seg	2 min 45 seg	7 min 12 seg
CPU 2	3 min 12 seg	52 seg	3 min 15 seg	5 min 54 seg	1 min 46 seg	7 min

A análise dos dados aponta para a superioridade do modelo WhisperX (Large-v2), contanto que executado em hardware com maior capacidade de paralelismo (CPU 2, i7). O ponto crucial da comparação é o tempo total para se obter uma transcrição utilizável.

No Áudio 2 (10:27 min), utilizando a CPU 2 (i7), o modelo Whisper Turbo levou 13 minutos e 54 segundos apenas para a transcrição básica (Tabela 1). Em contraste, o WhisperX (Large-v2) completou a transcrição (5 min 54 seg) e a etapa adicional de alinhamento (1 min 46 seg) em um tempo combinado de apenas 7 minutos e 40 segundos (Tabela 2).

Isso demonstra que, em hardware com maior contagem de núcleos, a arquitetura do WhisperX é drasticamente mais eficiente, entregando um resultado superior (com alinhamento temporal) em um tempo 44% menor do que o modelo base.

Curiosamente, o oposto ocorre na CPU 1 (i3), que possui menos núcleos e maior frequência de clock. Nela, o Whisper Turbo (10 min 40 seg) foi mais rápido que o tempo combinado do WhisperX (11 min 17 seg). Esta dinâmica valida que o WhisperX (Large-v2) é altamente otimizado para paralelismo (mais núcleos), enquanto o Whisper Turbo parece depender mais da frequência de clock de um único núcleo, reforçando a escolha do WhisperX para esta aplicação, que visa performance em hardware moderno.

Um dos grandes diferenciais alcançados foi a implementação de uma interface gráfica simples e objetiva, construída sobre o framework Tauri, que garante leveza e desempenho mesmo em hardwares mais modestos. Contudo, foi identificado durante os testes que, apesar da alta acurácia geral dos modelos e da performance validada, imprecisões pontuais tanto na

transcrição (erros de palavras) quanto na diarização (identificação incorreta do locutor) inevitavelmente ocorrem.

Diante dessa constatação, tornou-se essencial ir além da simples execução automática e desenvolver uma interface de pós-processamento mais robusta e editável. Para além da execução inicial, a ferramenta empodera o usuário na etapa de revisão. Foi implementada com sucesso a funcionalidade que permite a revisão e edição completa do material transcrito: o usuário pode alterar frases para corrigir as eventuais imprecisões dos modelos, gerenciar a identificação dos locutores (adicionando, renomeando ou excluindo conforme necessário) e inserir novos segmentos de texto vinculados a interlocutores específicos.

Por fim, a viabilidade prática da ferramenta é consolidada com a função de exportação do resultado final para PDF. Isso torna o produto da transcrição imediatamente utilizável em contextos profissionais ou acadêmicos. O projeto, portanto, não apenas cumpre seus requisitos técnicos, mas entrega valor real, democratizando o acesso a tecnologias avançadas de IA por meio de uma solução acessível, editável e funcional, como podemos ver nas figuras 5 e 6.




Figura 5: Página inicial do programa para fazer o upload do arquivo de áudio.




Figura 6: Página após o programa transcrever e diarizar o áudio.

O download do software estará disponível em código aberto neste link:

<https://github.com/RogerKoala/Koalizer>

REFERÊNCIAS

1. LEMES, H. H. Impacto da IA no desenvolvimento de softwares - Fundatec. Disponível em: <<https://www2.fundatec.org.br/2024/04/05/impacto-da-ia-no-desenvolvimento-de-softwares/>>. Acesso em: 5 ago. 2025.
2. NASCIMENTO, Luciano. O Brasil ocupa o 15o lugar em ranking de publicações acadêmicas sobre IA. Disponível em: <<https://agenciabrasil.ebc.com.br/geral/noticia/2025-03/inteligencia-artificial>>. Acesso em: 5 ago. 2025.

3. SEBRAE. O que é a automação robótica de processos (RPA)? Disponível em:
<https://sebrae.com.br/sites/PortalSebrae/artigos/o-que-e-a-automacao-robotica-de-processos-rpa_cd4016d8d6f28810VgnVCM1000001b00320aRCRD/>. Acesso em: 5 ago. 2025.
4. VANZOLINI. Cenário da IA no Brasil: desafios e perspectivas. Disponível em:
<<https://vanzolini.org.br/blog/cenario-da-ia-no-brasil/>>. Acesso em: 5 ago. 2025.
5. LIMA, C. Quantas empresas usam Inteligência Artificial no Brasil? Disponível em:
<<https://beanalytic.com.br/blog/quantas-empresas-usam-inteligencia-artificial-no-brasil/>>. Acesso em: 5 ago. 2025.
6. TIINSIDE. Empresas dobram uso de IA no Brasil, mostra estudo. Disponível em:
<<https://tiinside.com.br/09/05/2025/empresas-dobram-uso-de-ia-no-brasil-mostra-estudo/>>. Acesso em: 5 ago. 2025.
7. Novo Plano Brasileiro de Inteligência Artificial prevê o investimento de R\$ 1,76 bi para melhoria de serviços públicos. Disponível em:
<<https://www.gov.br/gestao/pt-br/assuntos/noticias/2024/julho/novo-plano-brasileiro-de-inteligencia-artificial-preve-o-investimento-de-r-1-76-bi-para-melhoria-de-servicos-publicos>>. Acesso em: 5 ago. 2025.
8. BARROSO, L. R.; MELLO, P. P. C.. Inteligência artificial: promessas, riscos e regulação. Algo de novo debaixo do sol. Revista Direito e Práxis, v. 15, n. 4, p. e84479, 2024.
9. Novo Plano Brasileiro de Inteligência Artificial prevê o investimento de R\$ 1,76 bi para melhoria de serviços públicos. Disponível em:
<<https://www.gov.br/gestao/pt-br/assuntos/noticias/2024/julho/novo-plano-brasileiro-de-inteligencia-artificial-preve-o-investimento-de-r-1-76-bi-para-melhoria-de-servicos-publicos>>. Acesso em: 5 ago. 2025.
10. GOOGLE. Gemini. Disponível em:
<<https://gemini.google.com/>>. Acesso em: 7 ago. 2025.
11. OPENAI. ChatGPT. Disponível em:
<<https://chat.openai.com/>>. Acesso em: 7 ago. 2025.
12. XAI. Grok. Disponível em:

<<https://grok.com/>>. Acesso em: 7 ago. 2025.

13. Brasil terá déficit de 530 mil profissionais de tecnologia até 2025, mostra estudo do Google. Disponível em:

<<https://g1.globo.com/trabalho-e-carreira/noticia/2023/05/31/brasil-tera-deficit-de-530-mil-profissionais-de-tecnologia-ate-2025-mostra-estudo-do-google.ghtml>>. Acesso em: 8 ago. 2025.

14. BARBOSA, L.; BARBOSA, L. Déficit: Indústria brasileira estima falta de 532 mil profissionais na transição energética - Brasscom. Disponível em:

<<https://brasscom.org.br/deficit-industria-brasileira-estima-falta-de-532-mil-profissionais-na-transicao-energetica/>>. Acesso em: 8 ago. 2025.

15. ALMEIDA, F. Escassez de Talentos É o Maior Entrave para Avanço da IA nas Empresas. Disponível em:

<<https://forbes.com.br/carreira/2025/05/escassez-de-talentos-e-o-maior-entrave-para-avanco-da-ia-nas-empresas/>>. Acesso em: 11 ago. 2025.

16. SARAIVA, J. Salários crescem mais em funções ligadas à IA. Disponível em:

<<https://valor.globo.com/carreira/noticia/2025/06/06/salarios-crescem-mais-em-funcoes-ligadas-a-ia.ghtml>>. Acesso em: 11 ago. 2025.

17. RAMOS DA INFORMÁTICA. Impacto da Inteligência Artificial no Mercado de Trabalho Brasileiro. Disponível em:

<<https://ramosdainformatica.com.br/impacto-da-inteligencia-artificial-no-mercado-de-trabalho-brasileiro/>>. Acesso em: 11 ago. 2025.

18. PLAQUET, Alexis; BREDIN, Hervé. Powerset multi-class cross entropy loss for neural speaker diarization. In: INTERNATIONAL CONFERENCE ON SPEECH COMMUNICATION AND TECHNOLOGY (INTERSPEECH), 2023.

19. BREDIN, Hervé. pyannote.audio 2.1 speaker diarization pipeline: principle, benchmark, and recipe. In: INTERNATIONAL CONFERENCE ON SPEECH COMMUNICATION AND TECHNOLOGY (INTERSPEECH), 2023.

20. RADFORD, Alec et al. Robust speech recognition via large-scale weak supervision. In: International conference on machine learning. PMLR, 2023. p. 28492-28518.

21. WANG, Quan et al. Diarizationlm: Speaker diarization post-processing with large language models. arXiv preprint arXiv:2401.03506, 2024.
22. H. Gish, M. . Siu, R. Rohlicek, Segregation of speakers for speech recognition and speaker identification, in: Proceedings of IEEE International Conference on Acoustics, Speech and Signal Processing, 1991, pp. 873–876.
23. S. S. Chen, P. S. Gopalakrishnan, Speaker, environment and channel change detection and clustering via the Bayesian Information Criterion, in: Tech. Rep., IBM T. J. Watson Research Center, 1998, pp. 127–132.
24. S. H. Shum, N. Dehak, R. Dehak, J. R. Glass, Unsupervised methods for speaker diarization: An integrated and iterative approach, IEEE Transactions on Audio, Speech, and Language Processing 21 (May 2013) 2015– 2028.
25. CHEN, Zhengyang et al. Attention-based encoder-decoder end-to-end neural diarization with embedding enhancer. IEEE/ACM Transactions on Audio, Speech, and Language Processing, v. 32, p. 1636-1649, 2024.
26. BASU, Joyanta et al. An overview of speaker diarization: Approaches, resources and challenges. In: 2016 Conference of The Oriental Chapter of International Committee for Coordination and Standardization of Speech Databases and Assessment Techniques (O-COCOSDA). IEEE, 2016. p. 166-171.
27. XU, Min et al. HMM-based audio keyword generation. In: **Pacific-Rim Conference on Multimedia**. Berlin, Heidelberg: Springer Berlin Heidelberg, 2004. p. 566-574.
28. Practical Cryptography. Disponível em:
<<http://practicalcryptography.com/miscellaneous/machine-learning/guide-mel-frequency-cepstral-coefficients-mfccs/>>. Acesso em: 22 ago. 2025.
29. BORATTO, Tales; CURY, Alexandre; GOLIATT, Leonardo. A fuzzy approach to drum cymbals classification. IEEE Latin America Transactions, v. 20, n. 9, p. 2172-2180, 2022.
30. ESCALFONI, Vitor Henrique de Moraes. Diarização de locutor utilizando redes neurais recorrentes. 2021. 75 f. Trabalho de Conclusão de Curso (Graduação em Engenharia de Computação) – Centro Federal de Educação Tecnológica Celso Suckow da Fonseca, Nova Friburgo, 2021.

31. Egocentric 4D Perception (EGO4D). Disponível em:
<<https://ego4d-data.org/workshops/eccv22/>>. Acesso em: 22 ago. 2025.
32. Implementing Speech-to-Text with Speaker Diarization: Comparing Pyannote and Sortformer on VAST.ai. Disponível em:
<<https://vast.ai/article/whisper-pyannote-sortformer-diarization-vast>>. Acesso em: 25 ago. 2025.
33. HERVÉ BREDIN. pyannote audio: neural building blocks for speaker diarization. Disponível em: <https://www.youtube.com/watch?v=37R_R82lfwA>. Acesso em: 26 ago. 2025.
34. DE, B. Transcrever áudio para texto: como funciona? Disponível em:
<<https://www.agbt.com.br/blog/transcrever-audio-para-texto-como-funciona/>>. Acesso em: 26 ago. 2025.
35. COUTINHO, Y. Transcrição de áudio: entenda como funciona. Disponível em:
<<https://nexustraducoes.com/transcricao-de-audio-entenda-como-funciona/>>. Acesso em: 26 ago. 2025.
36. Os desafios da transcrição de áudio para o profissional. Disponível em:
<<https://mundoescrito.com.br/desafios-da-transcricao-de-audio/>>. Acesso em: 26 ago. 2025.
37. HINTON, Geoffrey et al. Deep neural networks for acoustic modeling in speech recognition: The shared views of four research groups. IEEE Signal processing magazine, v. 29, n. 6, p. 82-97, 2012.
38. HUI, J. Speech Recognition — GMM, HMM. Disponível em:
<<https://jonathan-hui.medium.com/speech-recognition-gmm-hmm-8bb5eff8b196>>. Acesso em: 26 ago. 2025.
39. FORNEY, G. David. The viterbi algorithm. Proceedings of the IEEE, v. 61, n. 3, p. 268-278, 2005.
40. BERGMANN, D. aprendizado zero shot. Disponível em:
<<https://www.ibm.com/br-pt/think/topics/zero-shot-learning>>. Acesso em: 8 out. 2025.
41. BAIN, Max et al. Whisperx: Time-accurate speech transcription of long-form audio. arXiv preprint arXiv:2303.00747, 2023.

42. Interview transcription using WhisperX model, Part 1. - Valor Blog. Disponível em: <<https://valor-software.com/articles/interview-transcription-using-whisperx-model-part-1>>. Acesso em: 3 nov. 2025.
43. BAEVSKI, Alexei et al. wav2vec 2.0: A framework for self-supervised learning of speech representations. Advances in neural information processing systems, v. 33, p. 12449-12460, 2020.
44. Tauri 2.0. Disponível em: <<https://tauri.app>>. Acesso em: 3 nov. 2025.
45. Build cross-platform desktop apps with JavaScript, HTML, and CSS | Electron. Disponível em: <<https://www.electronjs.org/pt/>>. Acesso em: 3 nov. 2025.
46. NAHUM, D. Tauri vs. Electron for Tray Apps - Better Programming. Disponível em: <<https://medium.com/better-programming/tauri-vs-electron-for-tray-apps-ed15974f35ce>>. Acesso em: 3 nov. 2025.
47. Tauri vs Electron: A 2025 Comparison for Desktop Development. Disponível em: <<https://codeology.co.nz/articles/tauri-vs-electron-2025-desktop-development.html>>. Acesso em: 3 nov. 2025.